Analisis Risiko Banjir Pesisir Menggunakan Regresi Logistik Ordinal

Ayesha Danishafiqa[1], **Nashwa Nadilah**[2], **Riska Najihan Syabania**[3]
[1,2,3]Departemen Matematika FMIPA Universitas Indonesia
[1]ayesha.danishafiqa@ui.ac.id, [2]nashwa.nadilah@ui.ac.id, [3]riska.najihan@ui.ac.id

Abstrak

Banjir pesisir merupakan dampak perubahan iklim yang meningkatkan risiko di wilayah pesisir dan memerlukan analisis statistik yang tepat. Penelitian ini bertujuan untuk mengidentifikasi faktor-faktor yang memengaruhi tingkat risiko banjir pesisir menggunakan regresi logistik ordinal. Data yang digunakan berasal dari *Coastal Climate Risk Dataset* dengan 1.653 observasi di wilayah pesisir India bagian selatan. Tingkat risiko banjir diklasifikasikan ke dalam kategori rendah, sedang, dan tinggi, dengan variabel prediktor berupa faktor geografis dan lingkungan. Sebelum pemodelan, dilakukan standardisasi data serta pengujian asumsi multikolinearitas dan *proportional odds*. Pelanggaran asumsi pada satu prediktor diatasi menggunakan pendekatan *partial proportional odds model*. Pemilihan model dilakukan melalui *backward selection* berdasarkan AIC dan *likelihood ratio test*. Hasil menunjukkan bahwa bujur, elevasi, curah hujan rata-rata, kapasitas drainase rendah, jarak dari garis pantai, dan kejadian banjir historis berpengaruh signifikan terhadap tingkat risiko banjir pesisir.
Kata Kunci : banjir pesisir, regresi logistik ordinal, *proportional odds model*.

Abstract

Coastal flooding is an increasing impact of climate change that elevates risk in coastal regions and requires appropriate statistical analysis. This study aims to identify factors influencing coastal flood risk levels using an ordinal logistic regression approach. The analysis is based on the Coastal Climate Risk Dataset with 1,653 observations from southern coastal regions of India. Flood risk is classified into low, moderate, and high categories, with geographic and environmental variables as predictors. Prior to modeling, data standardization and assumption tests were conducted. A violation of the proportional odds assumption for one predictor was addressed using a partial proportional odds model. Model selection was performed using backward selection based on AIC and likelihood ratio test. The results indicate that longitude, elevation, average precipitation, low drainage capacity, coastal distance, and historical flood events significantly affect coastal flood risk levels.
Keywords: coastal flooding, ordinal logistic regression, proportional odds model

1 PENDAHULUAN

BANJIR PESISIR merupakan salah satu dampak perubahan iklim yang paling nyata dan berbahaya bagi masyarakat global. Laporan Intergovernmental Panel on Climate Change (IPCC) menunjukkan bahwa kenaikan muka air laut dan peningkatan kejadian banjir pesisir mengancam jutaan penduduk yang tinggal di dataran rendah pesisir pada pertengahan abad ke-21 [1]. Studi global memperkirakan lebih dari 300 juta orang berpotensi terdampak banjir pesisir tahunan pada tahun 2050 jika tidak dilakukan upaya adaptasi yang memadai [2]. Kondisi ini menunjukkan bahwa risiko banjir pesisir tidak lagi bersifat lokal, tetapi telah menjadi persoalan global yang membutuhkan analisis risiko berbasis data dan metode statistik yang andal.

Dalam kajian risiko banjir, tingkat risiko umumnya dinyatakan dalam kategori berjenjang, seperti rendah, sedang, dan tinggi, sehingga memerlukan pendekatan pemodelan yang mampu menangkap perbedaan tingkat risiko tersebut. Regresi logistik ordinal dengan pendekatan *proportional odds model* banyak digunakan untuk memodelkan hubungan antara variabel prediktor dan respons kategorikal berurutan karena efisien serta mudah diinterpretasikan [3].

Namun, asumsi *proportional odds* tidak selalu terpenuhi pada data empiris, sehingga pengembangan *partial proportional odds model* menjadi alternatif untuk menangani variabel yang melanggar asumsi tersebut [3]. Pendekatan ini memungkinkan fleksibilitas model tanpa mengabaikan struktur ordinal pada variabel respons.

Sejumlah penelitian sebelumnya telah memanfaatkan pendekatan statistik dan sistem informasi geografis untuk menganalisis kerentanan dan risiko banjir dengan mempertimbangkan faktor topografi, curah hujan, serta penggunaan lahan [4], [5]. Hasil penelitian tersebut menunjukkan bahwa elevasi, kemiringan lereng, dan kedekatan terhadap jaringan sungai merupakan faktor yang berpengaruh penting dalam pembentukan tingkat risiko banjir [4]. Namun, sebagian besar kajian tersebut masih memodelkan risiko banjir sebagai kejadian biner atau indeks komposit, sehingga pemanfaatan struktur kategorikal berurutan pada tingkat risiko banjir masih terbatas. Oleh karena itu, artikel ini bertujuan untuk mengisi celah tersebut dengan membandingkan spesifikasi model berdasarkan ukuran kecocokan, mengidentifikasi variabel-variabel yang berpengaruh signifikan dalam memodelkan tingkat risiko banjir pesisir menggunakan regresi logistik ordinal, serta menginterpretasikan kontribusi variabel prediktor terhadap perbedaan kategori risiko banjir pesisir.

2 METODE PENELITIAN

2.1 Data

Data yang digunakan dalam penelitian ini adalah data ”Coastal Climate Risk Dataset” yang diperoleh dari platform data sains Kaggle [6]. Dataset ini menyediakan kumpulan data atribut geospasial dan lingkungan yang mendetail yang merepresentasikan kondisi di wilayah pesisir yang rawan banjir. Data terdiri dari 1.653 observasi, di mana setiap observasi mewakili satu unit grid geografis yang didefinisikan oleh lokasi dan faktor fisik yang relevan. Berdasarkan rentang koordinat lintang dan bujur, data dikumpulkan dari wilayah pesisir India bagian selatan yang mencakup area dengan risiko banjir yang signifikan. Variabel respons (Y) dalam penelitian ini adalah tingkat risiko banjir (*Flood_Risk_Label*), sedangkan variabel prediktor (X) yang digunakan adalah sebagai berikut.

Tabel 1. Deskripsi Variabel Prediktor

Variabel	**Deskripsi**	**Level Variabel**
Grid_ID	Identitas unik untuk setiap grid spasial.	–
$X_1 =$ *Latitude*	Garis lintang lokasi observasi $(^\circ)$.	–
$X_2 =$ *Longitude*	Garis bujur lokasi observasi $(^\circ)$.	–
$X_3 =$ *Elevation*	Ketinggian lokasi observasi di atas permukaan laut (m).	–

$X_4 = Land_Use$	Jenis penggunaan lahan lokasi observasi.	0: *Agriculture* 1: *Forest* 2: *Industrial* 3: *Urban* 4: *Wetland*
$X_5 = Avg_Precipitation$	Rata-rata curah hujan tahunan (mm).	$-$
$X_6 = Soil_Type$	Jenis tanah lokasi.	0: *Clay* 1: *Loam* 2: *Peat* 3: *Sandy*
$X_7 = Drainage_Capacity$	Kapasitas drainase tanah.	0: *High* 1: *Low* 2: *Medium*
$X_8 = Coastal_Distance$	Jarak lokasi dari garis pantai (km).	$-$
$X_9 = Historical_Floods$	Jumlah kejadian banjir historis lokasi dalam 10 tahun terakhir.	$-$

2.2 *Scalling* Data

Scaling data merupakan proses transformasi variabel numerik untuk menyamakan skala pengukuran antar variabel prediktor. Dalam pemodelan risiko banjir, *scaling* diperlukan karena data mengandung variabel dengan satuan dan rentang nilai yang heterogen. Perbedaan skala ini dapat menyebabkan bias dalam estimasi parameter, dimana variabel dengan rentang nilai lebih besar akan mendominasi perhitungan model [7].

Proses *scaling* menggunakan metode *standardization (Z-score normalization)* dilakukan untuk mengatasi masalah ini. *Standardization* mentransformasi setiap variabel numerik sehingga memiliki mean nol dan standar deviasi satu yang meningkatkan stabilitas numerik algoritma optimasi dalam regresi logistik ordinal dan mempercepat konvergensi [8].

2.3 Konsep *Link Function* dalam GLM

Link Function $g(.)$ mendefinisikan hubungan antara mean respons dan kombinasi linear kovariat. Tujuan penggunaan *link function* adalah untuk menjamin nilai prediksi berada dalam domain yang valid serta menghubungkan model ke distribusi dalam keluarga eksponensial.

a) *Logit Link*

$$\text{logit}(P(Y \leq j)) = \log\left(\frac{P(Y \leq j)}{1 - P(Y \leq j)}\right) \tag{1}$$

Logit link digunakan karena memberikan interpretasi probabilitas melalui *odds ratio*, stabil secara numerik serta menjadi standar dalam model regresi logistik ordinal [10].

b) *Probit Link*

$$g(P(Y \leq j)) = \Phi^{-1}(P(Y \leq j)) \tag{2}$$

Probit link cocok digunakan ketika perubahan kategori respons mengikuti pola yang halus dan mendekati bentuk kurva berbentuk S (sigmoidal). Dengan kata lain, hubungan antara kovariat dan peluang respons naik secara bertahap, bukan tiba-tiba [10].

c) *Complementary Log-Log* (cloglog)

$$g(P(Y \leq j)) = \log[-\log(1 - P(Y \leq j))] \tag{3}$$

Cocok untuk kasus distribusi tidak simetris. Ada kategori yang sangat jarang muncul (misalnya kategori paling tinggi atau paling rendah) [10].

2.4 Asumsi pada *Odds Proportional Model*

Dalam membangun model regresi logistik ordinal, terdapat beberapa asumsi yang harus dipenuhi agar hasil estimasi dan interpretasi parameter menjadi valid [11]. Asumsi-asumsi tersebut dijelaskan sebagai berikut.

1. Tidak Terjadi Multikolinearitas
   Variabel prediktor diharapkan tidak memiliki korelasi yang sangat tinggi satu sama lain. Multikolinearitas dapat menyebabkan ketidakstabilan estimasi, memperbesar simpangan baku koefisien, serta mengurangi ketepatan interpretasi model.
2. *Proportional Odds* (*Parallel Lines Assumption*)
   Model mengasumsikan bahwa pengaruh setiap kovariat terhadap *log-odds* kumulatif bersifat konstan pada seluruh batas kategori respons. Artinya, *slope* (β) berada pada nilai yang sama untuk seluruh pembagian kategori ordinal sehingga hubungan prediktor–respons konsisten di setiap tingkat.

2.5 *Proportional Odds Model*

Proportional Odds Model atau *Cumulative Logit Model* merupakan pendekatan pemodelan yang digunakan ketika variabel respons memiliki kategori yang tersusun secara berurutan (ordinal). Model ini bekerja dengan memodelkan peluang kumulatif bahwa suatu observasi berada pada kategori tertentu atau kategori di bawahnya [11]. Misalkan variabel respons Y memiliki J kategori berurutan, yaitu $1, 2, ..., J$ Peluang kumulatif kategori ke-j didefinisikan sebagai berikut.

$$Pr(Y \leq j) = \sum_{k=1}^{j} \pi_k \quad \text{untuk } j = 1, 2, \ldots, J-1 \tag{4}$$

Cumulative logit model didefinisikan sebagai berikut.

$$\text{logit}\big(P(Y \leq j)\big) = \log\left(\frac{P(Y \leq j)}{1 - P(Y \leq j)}\right), \qquad j = 1, \ldots, J-1 \tag{5}$$

Bentuk umum *proportional odds model* dinyatakan sebagai berikut.

$$\text{logit}(P(Y \leq j)) = \alpha_j + \beta X, \quad j = 1, \ldots, J-1. \tag{6}$$

dengan:

α_j : *threshold* atau ambang pemisah kategori ke-j,

β : vektor koefisien yang menggambarkan pengaruh prediktor terhadap peluang kumulatif,

X : vektor variabel prediktor.

Probabilitas suatu observasi berada pada kategori tertentu dapat diperoleh dengan menghitung selisih antara peluang kumulatif dua kategori yang berurutan. Koefisien dalam model dapat ditafsirkan melalui nilai *odds ratio*, yaitu $exp(\beta)$ yang menunjukkan seberapa besar perubahan odds kumulatif akibat kenaikan satu unit pada variabel prediktor.

2.6 Metode Pemilihan Variabel Prediktor

Pemilihan variabel prediktor dilakukan melalui serangkaian evaluasi. Tahap awal terdiri dari pemeriksaan multikolinearitas dan uji *nominal test* untuk menguji asumsi *proportional odds*. Lalu selanjutnya menggunakan metode *backward selection*, di mana variabel yang tidak signifikan dihapus secara bertahap dan model dibandingkan berdasarkan Akaike Information Criterion (AIC). Proses ini diulang hingga diperoleh model dengan performa terbaik yang stabil dan memenuhi asumsi dasar [9].

2.7 Uji Kecocokan Model

Setelah model regresi logistik ordinal diestimasi, dilakukan evaluasi terhadap tingkat kecocokan model dengan data observasi. Uji kecocokan model bertujuan untuk menilai kesesuaian model yang dibangun dengan pola data aktual, mengidentifikasi kemungkinan ketidaksesuaian antara nilai prediksi dan observasi, serta membandingkan beberapa spesifikasi model untuk menentukan yang terbaik [11].

Dilakukan Likelihood Ratio Test (LRT) untuk model bersarang (*nested models*) yang membandingkan model sederhana (M_0) dengan model yang lebih kompleks (M_1), dengan M_0 merupakan kasus khusus dari M_1 [8]. Statistik uji LRT dihitung sebagai:

$$G^2 = D_0 - D_1 = -2[L(\hat{\mu}_0) - L(\hat{\mu}_1)], \tag{7}$$

dengan $L(\hat{\mu_0})$ dan $L(\hat{\mu_1})$ masing-masing adalah log-likelihood model M_0 dan M_1. Dibawah

hipotesis nol bahwa model sederhana (M_0) benar, statistik G^2 mengikuti distribusi chi-square dengan $df = p_1 - p_0$ [11].

Kemudian dilakukan juga uji LRT berbasis deviance, dengan membandingkan model penuh dan model null. Pendekatan ini digunakan karena lebih sesuai untuk regresi logistik ordinal dengan data individual dibandingkan uji Pearson Chi-square berbasis sel frekuensi. Hipotesis yang digunakan adalah:

H_0: Model null (tanpa variabel prediktor) telah memadai dalam menjelaskan data.

H_1: Tidak demikian.

Kriteria pengujian adalah menolak H_0 jika nilai $p - value < 0,05$.

2.8 Uji Signifikansi Parameter Model

Pengujian signifikansi masing-masing parameter dalam model dilakukan dengan menggunakan Uji Wald. Metode ini didasarkan pada galat standar yang dihitung dari invers matriks informasi Fisher, yang nilainya bergantung pada parameter yang diestimasi. Dengan menggunakan estimator *maximum likelihood (mle)* tanpa kendala (tanpa asumsi hipotesis nol), standar error dari estimasi parameter didapatkan. Hipotesis yang digunakan ialah:

$$H_0 : \beta_j = 0$$

$$H_1 : \beta_j \neq 0$$

Dengan statistik uji:

$$W = \left(\frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \right)^2 \sim \chi^2_{(1)}, \tag{8}$$

dimana $\hat{\beta}_j$ adalah estimasi parameter dari mle dan $SE(\hat{\beta}_j)$ adalah galat bakunya [11].

2.9 Kriteria Pemilihan Model (Akaike Information Critetrion (AIC))

Langkah terakhir dalam analisis regresi logistik ordinal *proportional odds* adalah menentukan atau memilih model terbaik dari beberapa model yang telah dikembangkan. Digunakan kriteria informasi Akaike (AIC) untuk mengevaluasi keseimbangan antara kecocokan model sebenarnya dan kompleksitasnya. Formula AIC didefinisikan sebagai berikut:

$$AIC = -2 \ln L + 2p, \tag{9}$$

dimana L adalah *likelihood* model dan p adalah jumlah parameter yang diestimasi termasuk parameter *intercept*. Model terbaik ditentukan dari model dengan nilai AIC terkecil.

3 HASIL DAN PEMBAHASAN

3.1 Hasil Uji Asumsi

Setelah dilakukan *scalling* pada variabel numerik, akan dilakukan uji asumsi sebelum pembentukan model regresi logistik ordinal (*proportional odds*).

3.1.1 Cek Multikolinearitas

Pertama-tama, akan lakukan uji multikolinearitas untuk memeriksa apakah ada hubungan linear yang kuat antarvariabel prediktor dalam model regresi.

Tabel 2. Hasil Uji Multikolinearitas dengan VIF

Variabel	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	X_9
VIF	1.005	1.008	1.005	1.004	1.007	1.005	1.004	1.005	1.004

Berdasarkan hasil uji multikolinearitas yang disajikan pada Tabel 2, dapat disimpulkan bahwa tidak terdapat masalah multikolinearitas serius di antara variabel prediktor. Nilai-nilai tersebut jauh di bawah ambang batas umum yang digunakan sebagai indikasi multikolinearitas, yaitu VIF > 5. Hal ini menunjukkan bahwa setiap variabel prediktor dalam model relatif independen dan tidak memiliki korelasi linier yang tinggi dengan variabel prediktor lainnya. Dengan demikian, dapat dinyatakan bahwa model regresi yang dibangun bebas dari gangguan multikolinearitas.

3.1.2 *Proportional Odds (Parallel Lines Assumption)*

Selanjutnya, akan dilakukan uji asumsi terkait *proportional odds* menggunakan *nominal test*.

H_0: Model memenuhi asumsi *proportional odds* untuk prediktor tersebut

H_1: Model tidak memenuhi asumsi *proportional odds* untuk prediktor tersebut

Jika nilai *p-value* $> \alpha$, maka H_0 tidak ditolak yang berarti model memenuhi asumsi *proportional odds* untuk prediktor tersebut.

Tabel 3. Hasil Uji Signifikansi Parameter Model

Variabel	X_1	X_2	X_3	X_4
Pr(>Chi)	0.32228	0.04930	0.62543	0.48469

Variabel	X_5	X_6	X_7	X_8	X_9
Pr(>Chi)	0.73891	0.18173	0.69725	0.07262	0.06929

Secara keseluruhan, model dapat dianggap memenuhi asumsi *proportional odds* karena hanya satu dari sembilan prediktor yang menunjukkan pelanggaran asumsi. Untuk prediktor X_2 (Longitude) yang melanggar asumsi, dapat dipertimbangkan untuk menggunakan model *partial proportional odds* .

3.2 Pembentukan Model Regresi Ordinal (Proprotional Odds Model)

Berdasarkan hasil pengujian asumsi *(proportional odds)*, sebagian besar variabel prediktor memenuhi asumsi tersebut, sementara satu variabel, yaitu Longitude, menunjukkan pelanggaran asumsi. Oleh karena itu, pembentukan model regresi ordinal akan dilakukan menggunakan pendekatan *partial proportional odds model*, yang memungkinkan pelonggaran asumsi *(proportional odds)* pada variabel tertentu tanpa mengabaikan struktur model regresi ordinal secara keseluruhan.

Selanjutnya, model regresi ordinal dibangun dengan menggunakan *link function logit* sesuai dengan fokus penelitian, yaitu pada model logistik ordinal *(proportional odds model)*. *Link logit* dipilih karena lebih mudah diinterpretasikan dibandingkan *link function* lain, seperti *probit* dan cloglog. Dengan *link function* tersebut, proses pembentukan model kemudian dilakukan menggunakan metode *backward selection*, dimulai dengan model yang memuat seluruh variabel prediktor dan dilanjutkan dengan penghapusan variabel yang tidak signifikan secara statistik $(p - value < 0.05)$ secara bertahap, dimulai dari variabel dengan $(p - value)$ terbesar hingga diperoleh model akhir yang hanya memuat variabel yang signifikan. Rincian model regresi beserta nilai AIC pada setiap tahap seleksi disajikan pada tabel berikut.

Tabel 4. Ringkasan Model Regresi dan AIC

Model	**Bentuk Model**	**AIC**
1	$\alpha_j+\beta_1X_1+\beta_2X_2+\beta_3X_3+\beta_4X_4+\beta_5X_5+\beta_6X_6+\beta_7X_7+\beta_8X_8+\beta_9X_9$	1291.511
2	$\alpha_j+\beta_1X_1+\beta_2X_2+\beta_3X_3+\beta_5X_5+\beta_6X_6+\beta_7X_7+\beta_8X_8+\beta_9X_9$	1285.291
3	$\alpha_j+\beta_1X_1+\beta_2X_2+\beta_3X_3+\beta_5X_5+\beta_7X_7+\beta_8X_8+\beta_9X_9$	1280.916
4	$\alpha_j+\beta_2X_2+\beta_3X_3+\beta_5X_5+\beta_7X_7+\beta_8X_8+\beta_9X_9$	1281.264

Dalam proses *backward selection*, digunakan *likelihood ratio test* (LRT) untuk membandingkan model penuh dengan model tereduksi yang dibangun dengan *link function* yang sama. Pengujian ini bertujuan untuk menguji apakah penghapusan suatu variabel prediktor membuat model menjadi kurang baik dalam menjelaskan data. Hasil pengujian *likelihood ratio test* disajikan pada tabel berikut.

Tabel 5. LR Test M1 vs M2

Model	**Pr(>Chisq)**
1	
2	0.7761

Tabel 6. LR Test M2 vs M3

Model	**Pr(>Chisq)**
2	
3	0.6538

Tabel 7. LR Test M3 vs M4

Model	**Pr(>Chisq)**
3	
4	0.1255

Hasil *likelihood ratio test* menunjukkan bahwa penghapusan variabel pada setiap tahap *backward selection* tidak menyebabkan model menjadi kurang baik dalam menjelaskan data. Dengan demikian, model yang lebih sederhana tetap dapat digunakan tanpa mengurangi kemampuan model dalam menjelaskan data.

3.3 Model Terbaik

Berdasarkan hasil *likelihood ratio test*, penghapusan variabel secara bertahap dari Model 1 hingga Model 4 tidak menyebabkan penurunan kecocokan model yang signifikan. Evaluasi menggunakan kriteria Akaike Information Criterion (AIC) menunjukkan bahwa Model 3 memiliki nilai AIC paling kecil dibandingkan model lainnya. Namun, perbedaan nilai AIC antara Model 3 dan Model 4 sangat kecil (ΔAIC < 1). Dalam kondisi selisih AIC yang sangat kecil, nilai AIC tidak memberikan informasi yang cukup untuk membedakan Model 3 dan Model 4 secara jelas [12]. Oleh karena itu, pemilihan model tidak hanya didasarkan pada nilai AIC terendah, tetapi juga mempertimbangkan peran dan kontribusi masing-masing variabel.

Penghilangan variabel *Latitude* pada Model 4 dilakukan dengan mempertimbangkan hasil estimasi parameter dan makna konseptual variabel tersebut. Pada Model 3, variabel *Latitude* tidak menunjukkan signifikansi statistik yang mengindikasikan bahwa variabel tersebut tidak memberikan kontribusi yang kuat dalam menjelaskan variasi risiko banjir pesisir. Keberadaan parameter yang tidak signifikan secara statistik pada model dengan nilai AIC yang sangat berdekatan menunjukkan bahwa parameter tersebut bersifat tidak informatif, yaitu menambah kompleksitas model tanpa memberikan informasi tambahan yang berarti terhadap kecocokan model [12]. Dalam konteks seleksi model berbasis AIC, kondisi ini menunjukkan bahwa penghilangan parameter tersebut tidak mengurangi kemampuan model dalam menjelaskan data.

Selain itu, *latitude* hanya merepresentasikan posisi geografis dan tidak secara langsung mencerminkan mekanisme fisik yang memengaruhi terjadinya banjir pesisir. Variasi risiko banjir pesisir telah dijelaskan secara lebih bermakna oleh variabel lingkungan dan topografis yang memiliki keterkaitan fisik yang jelas, seperti elevasi, jarak dari garis pantai, curah hujan, kapasitas drainase, serta riwayat kejadian banjir. Tidak ditemukannya multikolinearitas pada variabel *latitude* hanya menunjukkan bahwa variabel tersebut tidak berkorelasi secara linear dengan variabel lain, namun tidak berarti bahwa variabel tersebut esensial secara substantif.

Dengan demikian, penghilangan variabel *latitude* menghasilkan model yang lebih sederhana dan lebih mudah diinterpretasikan, tanpa mengurangi kemampuan model dalam menjelaskan data. Berdasarkan pertimbangan statistik dan konseptual serta prinsip kesederhanaan model, Model 4 ditetapkan sebagai model terbaik dalam analisis risiko banjir pesisir. Adapun hasil estimasi parameter berdasarkan Model 4 ialah sebagai berikut.

Tabel 8. Hasil Estimasi Parameter Model Logit Terbaik

Parameter	**Estimate**	**Std. Error**	**z value**	**Pr($>\|z\|$)**	**Signifikansi**
(Intercept):1	3.29051	0.19129	17.202	<2e-16	***
(Intercept):2	6.88344	0.30666	22.447	<2e-16	***
Longitude:1	-0.16250	0.08151	-1.994	0.0462	*
Longitude:2	0.16408	0.14870	1.103	0.2698	

Elevation	1.01875	0.08404	12.122	<2e-16	***
Avg_Precipitation	-0.91852	0.08383	-10.957	<2e-16	***
Drainage_CapacityLow	-3.69262	0.22524	-16.394	<2e-16	***
Drainage_CapacityMedium	0.12220	0.22572	0.541	0.5882	
Coastal_Distance	1.22217	0.08829	13.843	<2e-16	***
Historical_Floods	-1.34513	0.08426	-15.964	<2e-16	***
Residual Deviance:				1261.264	
Null Deviance:				2315.125	

Berdasarkan hasil estimasi model, sebagian besar variabel menunjukkan pengaruh yang signifikan terhadap tingkat risiko banjir pada taraf signifikansi 0.05, yaitu Elevation, Avg_Precipitation, Drainage_CapacityLow, Coastal_Distance, dan Historical_Floods. Variabel Longitude menunjukkan pengaruh yang signifikan dalam membedakan wilayah dengan risiko *low* dibandingkan *moderate* dan *high*, tetapi tidak signifikan dalam membedakan wilayah dengan risiko *low* dan *moderate* dibandingkan *high*. Sementara itu, Drainage_CapacityMedium tidak menunjukkan perbedaan yang signifikan dibandingkan kategori Drainage_CapacityHigh.

Kemudian, kecocokan model juga dievaluasi menggunakan uji rasio likelihood (*Likelihood Ratio Test*) dengan membandingkan model penuh dan model null. Hasil pengujian menunjukkan penurunan nilai *deviance* dari 2315.125 pada model null menjadi 1261.264 pada model terpilih. Selanjutnya, uji rasio likelihood menghasilkan nilai $\chi^2 = 1053.9$ dengan 8 derajat kebebasan dan p-*value* $< 2.2 \times 10^{-16}$ sehingga model regresi logistik ordinal dinyatakan layak digunakan. Dengan demikian, dapat dirumuskan persamaan regresi logistik ordinal sebagai berikut.

$$\begin{aligned}\log\left(\frac{P(Y \leq 1)}{P(Y > 1)}\right) &= 3.29051 - 0.16250X_2 + 1.01875X_3 - 0.91852X_5 \\ &\quad - 3.69262X_{7:1} + 0.12220X_{7:2} + 1.22217X_8 - 1.34513X_9\end{aligned} \tag{10}$$

$$\begin{aligned}\log\left(\frac{P(Y \leq 2)}{P(Y > 2)}\right) &= 6.88344 - 0.16408X_2 + 1.01875X_3 - 0.91852X_5 \\ &\quad - 3.69262X_{7:1} + 0.12220X_{7:2} + 1.22217X_8 - 1.34513X_9\end{aligned} \tag{11}$$

3.4 Evaluasi Kesesuaian Model melalui Perbandingan Probabilitas Observasi dan Hasil Prediksi

Sebagai bentuk validasi tambahan terhadap model yang dibangun, berikut disajikan perbandingan visual antara probabilitas observasi (*observed*) dan hasil prediksi (*fitted*) untuk setiap variabel prediktor signifikan. Grafik ini bertujuan untuk mengevaluasi kecocokan model secara grafis dan memastikan bahwa pola risiko yang diprediksi sesuai dengan realita data.

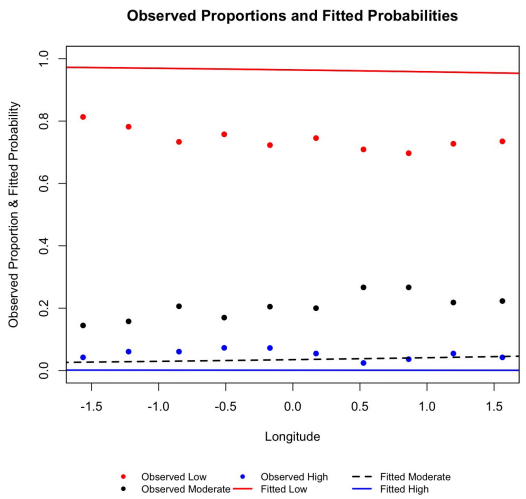

Gambar 1 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Longitude

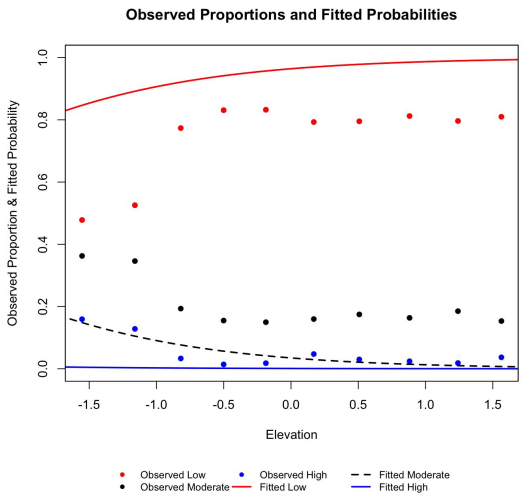

Gambar 2 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Elevation

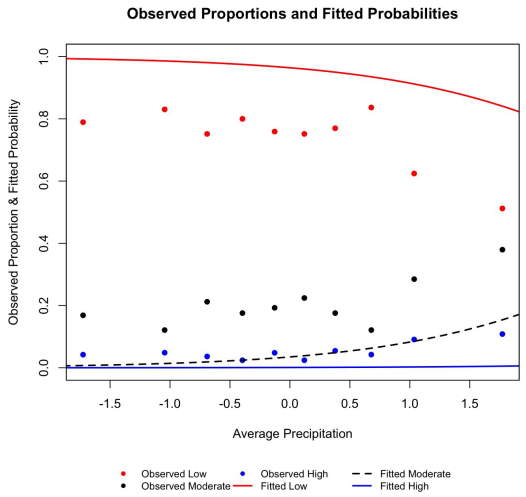

Gambar 3 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Average Precipitation

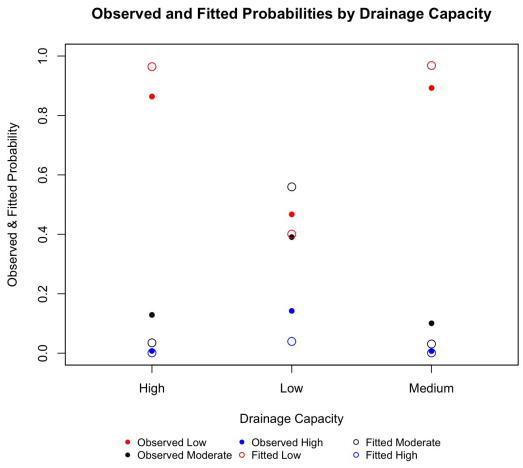

Gambar 4 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Drainage Capacity

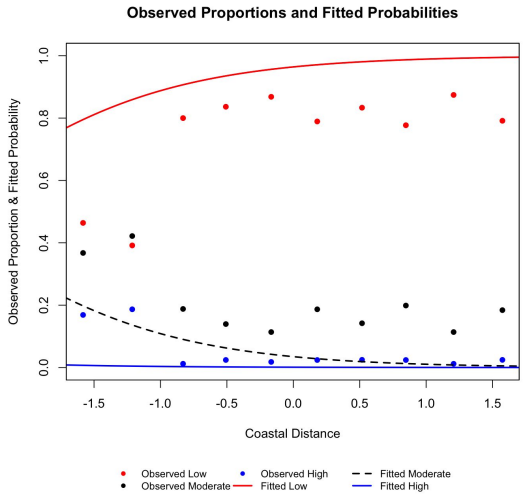

Gambar 5 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Coastal Distance

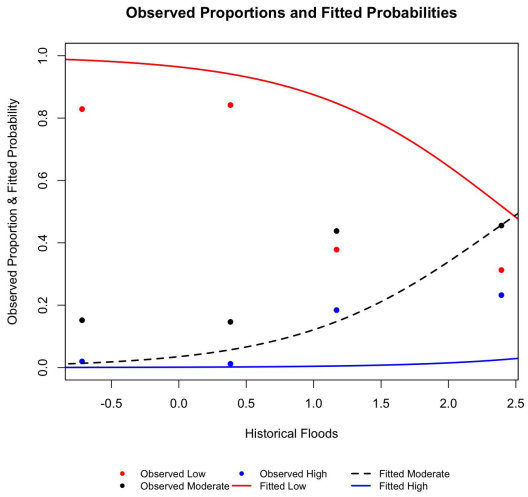

Gambar 6 Ilustrasi *Observed* vs. *Fitted* berdasarkan Variabel Historical Floods

Grafik perbandingan antara probabilitas observasi (*observed*) dan hasil prediksi (*fitted*) menunjukkan bahwa model regresi logistik ordinal yang dibangun secara umum mampu mereproduksi pola hubungan antara prediktor dan kategori risiko banjir dengan baik. Pada variabel Elevation, Avg_Precipitation, Drainage_Capacity, dan Coastal_Distance, pola kurva *fitted* terlihat searah dengan proporsi teramati. Hal ini mengindikasikan bahwa model berhasil menangkap tren penurunan risiko seiring kenaikan elevasi dan jarak dari pantai, serta peningkatan risiko pada curah hujan tinggi dan drainase rendah.

Pada variabel Longitude, digunakan pendekatan *partial proportional odds* yang memungkinkan koefisien berbeda untuk setiap ambang kategori. Secara visual, terlihat bahwa model mampu mengikuti pola perubahan risiko sepanjang bujur, meskipun terdapat kompleksitas spasial yang tidak sepenuhnya linier. Sementara itu, pada variabel Historical_Floods, model tetap konsisten dalam memperkirakan peningkatan risiko *high* seiring bertambahnya kejadian banjir historis, meskipun terdapat variasi kecil pada kategori *low*. Hal ini menunjukkan bahwa model lebih efektif dalam membedakan wilayah dengan risiko *moderate* dan *high* dibandingkan dalam menangkap variasi rinci pada kategori risiko *low*.

Perlu dicatat bahwa kesesuaian antara probabilitas *observed* dan *fitted* tidak selalu terlihat sama pada setiap titik pengamatan. Pada beberapa variabel numerik, probabilitas *fitted* untuk kategori risiko tinggi cenderung rendah dan relatif stabil. Kondisi ini sejalan dengan probabilitas *observed* pada kategori risiko tinggi yang relatif kecil karena adanya keterbatasan jumlah kejadian risiko tinggi dalam data. Akibatnya, model lebih menggambarkan kecenderungan hubungan secara umum daripada mengikuti variasi kecil pada setiap kelompok data.

Secara keseluruhan, kesesuaian visual antara probabilitas teramati dan hasil pemodelan menguatkan validitas model dalam menjelaskan variasi risiko banjir pesisir. Grafik ini tidak hanya memperkuat signifikansi statistik dari variabel prediktor, tetapi juga memberikan keyakinan bahwa model dapat diandalkan untuk identifikasi wilayah berisiko dan mendukung pengambilan keputusan mitigasi berbasis data.

3.5 Interpretasi Kovariat Model Terbaik

Tabel 9. Interpretasi Koefisien Tiap Variabel Prediktor

Prediktor	**Odds Ratio** $(\exp(\beta_i))$	**Interpretasi**
Longitude:1	0.85001217	Setiap kenaikan 1 unit Longitude, dengan asumsi variabel prediktor lainnya konstan, odds kumulatif berada pada kategori *low* (dibanding kategori *moderate* dan *high*) turun menjadi 0.85001217 kali lipat.

Longitude:2	1.17831393	Pada peralihan dari kategori risiko *moderate* ke *high*, Longitude tidak menunjukkan pengaruh yang signifikan terhadap risiko banjir, dengan asumsi variabel prediktor lainnya konstan.
Elevation	2.76973076	Setiap kenaikan 1 unit Elevation, dengan asumsi variabel prediktor lainnya konstan, odds kumulatif berada pada kategori risiko $\leq j$ (dibanding kategori $> j$) naik menjadi 2.76973076 kali lipat untuk $j = 1, 2$.
Avg_Precipitation	0.39910782	Setiap kenaikan 1 unit Avg_Precipitation, dengan asumsi variabel prediktor lainnya konstan, odds kumulatif berada pada kategori risiko $\leq j$ (dibanding kategori $> j$) turun menjadi 0.39910782 kali lipat untuk $j = 1, 2$.
Drainage_Capacity Low	0.02490675	Dengan asumsi variabel prediktor lainnya konstan, wilayah dengan Drainage_CapacityLow mengalami penurunan odds kumulatif untuk berada pada kategori risiko $\leq j$ (dibanding kategori $> j$) menjadi 0.02490675 kali dibandingkan wilayah dengan Drainage_CapacityHigh untuk $j = 1, 2$.
Drainage_Capacity Medium	1.12998201	Dengan asumsi variabel prediktor lainnya konstan, wilayah dengan Drainage_CapacityMedium tidak menunjukkan perbedaan tingkat risiko banjir yang signifikan dibandingkan wilayah dengan Drainage_CapacityHigh.
Coastal_Distance	3.39456138	Setiap kenaikan 1 unit Coastal_Distance, dengan asumsi variabel prediktor lainnya konstan, odds kumulatif berada pada kategori risiko $\leq j$ (dibanding kategori $> j$) naik menjadi 3.39456138 kali lipat untuk $j = 1, 2$.
Historical_Floods	0.26050457	Setiap kenaikan 1 unit Historical_Floods, dengan asumsi variabel prediktor lainnya konstan, odds kumulatif berada pada kategori risiko $\leq j$ (dibanding kategori $> j$) turun menjadi 0.26050457 kali lipat untuk $j = 1, 2$.

Keterangan: $j = 1$: kategori *low*, $j = 2$: kategori *moderate*.

4 KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, didapatkan beberapa kesimpulan sebagai berikut.

1. Model regresi logistik ordinal dengan pendekatan *partial proportional odds* ditetapkan sebagai model terbaik dalam memodelkan risiko banjir pesisir. Pemilihan model ini didasarkan pada hasil *likelihood ratio test* yang menunjukkan bahwa penyederhanaan model tidak menurunkan kecocokan secara signifikan, serta evaluasi nilai AIC yang mendukung model dengan struktur lebih sederhana. Melalui proses *backward selection* dan prinsip *parsimony*, Model 4 dipilih karena mampu menjelaskan data dengan baik tanpa memasukkan variabel yang tidak esensial secara substantif.
2. Hasil analisis menunjukkan bahwa variabel Longitude, Elevation, Average Precipitation, Drainage Capacity (Low), Coastal Distance, dan Historical Floods memiliki pengaruh yang signifikan terhadap tingkat risiko banjir pesisir.
3. Pengaruh masing-masing variabel prediktor terhadap perbedaan kategori risiko banjir pesisir (*low, moderate* dan *high*) dianalisis melalui interpretasi odds ratio pada model terpilih. Interpretasi ini memberikan pemahaman kuantitatif mengenai peluang transisi antar tingkat risiko akibat perubahan pada setiap variabel prediktor, sehingga memungkinkan identifikasi faktor-faktor yang meningkatkan atau menurunkan risiko banjir pesisir secara lebih terperinci.

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, penelitian selanjutnya disarankan untuk melakukan hal sebagai berikut.

1. Menggunakan data dengan cakupan wilayah pesisir yang lebih luas agar hasil pemodelan memiliki tingkat generalisasi yang lebih baik.
2. Mempertimbangkan perluasan skala variabel respons serta penambahan variabel prediktor yang relevan, seperti faktor pasang surut dan dinamika perubahan garis pantai, guna meningkatkan ketepatan model dalam mendukung pengelolaan risiko banjir pesisir secara berkelanjutan.

5 UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada semua pihak yang telah memberikan dukungan dalam pelaksanaan penelitian ini. Ucapan terima kasih disampaikan kepada pihak-pihak yang telah menyediakan dan memfasilitasi data yang digunakan dalam analisis risiko banjir pesisir. Penulis juga menyampaikan apresiasi kepada para peneliti dan ahli di bidang statistika dan pemodelan atas kontribusi pemikiran dalam pengembangan dan penerapan metode regresi logistik ordinal (*proportional odds model*) yang digunakan dalam penelitian ini. Selanjutnya, penulis mengucapkan terima kasih kepada Program Studi Ilmu Aktuaria Universitas Indonesia atas dukungan, fasilitas, dan kesempatan yang diberikan sehingga penelitian ini dapat terlaksana dengan baik. Terakhir, penulis menyampaikan apresiasi kepada Outlet Kopi Kenangan,

Ruko Pondok Cina, Depok yang telah menyediakan fasilitas dan ruang kerja yang nyaman selama proses penelitian, sehingga turut mendukung kelancaran penyelesaian penelitian ini.

6 DAFTAR PUSTAKA

[1] Intergovernmental Panel on Climate Change. *Climate Change 2021: The Physical Science Basis*. Cambridge University Press, 2021. Available at: ipcc.ch/report/ar6/wg1/

[2] S. A. Kulp and B. H. Strauss, "New elevation data triple estimates of global vulnerability to sea-level rise and coastal flooding," *Nature Climate Change*, vol. 9, pp. 681–686, 2019. doi:10.1038/s41558-019-0542-8.

[3] A. Agresti, *Foundations of Linear and Generalized Linear Models*. Wiley, 2015.

[4] A. E. M. Al-Juaidi, A. M. Nassar, and O. E. M. Al-Juaidi, "Evaluation of flood susceptibility mapping using logistic regression and GIS conditioning factors," *Arabian Journal of Geosciences*, vol. 11, no. 24, pp. 1–10, 2018. Available at: researchgate.net/publication/329587278

[5] K. C. Swain, C. Singha, and L. Nayak, "Flood susceptibility mapping through the GIS-AHP technique using the cloud," *ISPRS International Journal of Geo-Information*, vol. 9, no. 12, p. 720, 2020. Available at: mdpi.com/2220-9964/9/12/720

[6] Ziya, *Coastal Climate Risk Dataset*. Kaggle, 2025. Retrieved December 6, 2025, from kaggle.com/datasets/ziya07/coastal-climate-risk-dataset/data

[7] M. Kuhn and K. Johnson, *Applied Predictive Modeling*. Springer, 2013.

[8] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning*. Springer, 2013.

[9] S. Devila, *PPT Kuliah Model Linier Lanjut Pekan 2*. Universitas Indonesia, 2025.

[10] S. Devila, *PPT Kuliah Model Linier Lanjut Pekan 3*. Universitas Indonesia, 2025.

[11] S. Devila, *PPT Kuliah Model Linier Lanjut Pekan 6*. Universitas Indonesia, 2025.

[12] Proceedings of the Royal Society B: Biological Sciences. "Uninformative parameters and model selection using Akaike's Information Criterion," vol. 290, no. 2009, article 20231261, 2023. doi:10.1098/rspb.2023.1261.

[13] Towards Data Science, *Partial Proportional Odds Model in R*. Retrieved December 13, 2025, from towardsdatascience.com/partial-proportional-odd-model-in-r-dc5face36e40/